
Syllabus

Especialización en Databricks Data Engineering
y Lakehouse sobre AWS

36 horas · 18 sesiones · Nivel fundamental a intermedio

1. Información general

Campo	Definición
Programa	Especialización en Databricks Data Engineering y Lakehouse sobre AWS
Cliente	La Positiva
Duración total	36 horas cronológicas
Organización	18 sesiones de 2 horas
Horas de formación	30 horas
Repasos aplicados y evaluados	4 horas
Caso de uso final	2 horas
Participantes	31 profesionales con perfiles técnicos, analíticos y de negocio
Nivel	Fundamental a Intermedio
Modalidad	Virtual síncrona
Cloud de referencia	Amazon Web Services (AWS)
Plataforma principal de práctica	Databricks Free Edition o entorno habilitado por el cliente
Enfoque principal	Uso práctico e integral de la plataforma Databricks

2. Propósito del programa

Desarrollar la capacidad de utilizar Databricks como una plataforma integrada de datos, analítica e inteligencia artificial sobre AWS. Al finalizar, los participantes podrán identificar qué herramienta utilizar ante una necesidad concreta, comprender cómo fluye y se gobierna la información, preparar datos, crear productos analíticos, automatizar procesos y explorar capacidades de IA.

El programa mantiene los fundamentos de Cloud, Lakehouse, Spark y Delta Lake necesarios para comprender la plataforma, pero no busca especializar al grupo en programación avanzada con Spark. SQL será la vía principal para análisis; Python y PySpark se utilizarán cuando aporten valor al procesamiento o permitan comprender cómo opera Databricks.

3. Resultados de aprendizaje

Al finalizar el programa, el participante podrá:

- navegar y organizar recursos en Workspace
- reconocer el propósito de Catalog, Compute, SQL Editor, notebooks, dashboards, Jobs, Pipelines, Alerts, Genie, AI/ML y Apps
- elegir entre SQL, Python, PySpark y herramientas visuales según el escenario
- ingerir y preparar datos estructurados y semiestructurados
- explicar y aplicar una arquitectura Medallion simplificada
- crear tablas, vistas, consultas, visualizaciones e indicadores reutilizables
- construir y monitorear un flujo de datos con dependencias
- automatizar una tarea repetitiva de reportería o preparación de datos
- aplicar principios de calidad, trazabilidad, seguridad y mínimo privilegio
- utilizar IA generativa para producir, explicar y validar consultas o código
- consultar datos de negocio con Genie y comprender el alcance de los agentes
- reconocer cuándo conviene un dashboard, una aplicación o un Data Product
- interpretar resultados de un modelo analítico sencillo
- considerar reutilización, costos y buenas prácticas antes de crear nuevos activos

4. Enfoque pedagógico

La capacitación mantiene aproximadamente:

- 40% conceptos, arquitectura y criterios de decisión.
- 60% demostraciones, ejercicios y retos aplicados.

Cada tema de plataforma seguirá la secuencia:

```

Necesidad de negocio
↓
Herramienta de Databricks
↓
Demostración breve
↓
Actividad práctica
↓
Resultado verificable
↓
Buena práctica de uso
  
```

La Sesión 1 conserva su contenido actual. Las sesiones 6 y 12 no introducen contenido nuevo: integran y evalúan lo aprendido. La Sesión 18 reserva sus 120 minutos para elaborar y entregar el caso de uso final.

5. Distribución de horas

Formación

#	Módulo	Horas
1	Fundamentos Cloud, AWS y Arquitectura Moderna de Datos	4
2	Navegación y trabajo en la Plataforma Databricks	4
3	Ingesta y Preparación Visual de Datos	2
4	Lakehouse, Delta Lake y Arquitectura Medallion	2
5	SQL, Python y PySpark aplicados	2
6	Lakeflow Pipelines, Calidad e Ingesta Incremental	2
7	Databricks SQL, Dashboards, Jobs y Alerts	4
8	Unity Catalog, Gobierno y Buenas Prácticas	4
9	Analítica, IA generativa, Genie y Agents	4
10	Databricks Apps, Data Products y Disponibilización	2
	Subtotal de formación	30

Consolidación y evaluación

Actividad	Sesión	Horas	Peso
Repaso aplicado y Evaluación 1	6	2	30%
Repaso aplicado y Evaluación 2	12	2	30%
Caso de uso final	18	2	40%
		6	100%

Total del programa: 36 horas.

6. Plan de sesiones

Sesión	Módulo	Tema principal	Experiencia predominante
1	M1	Fundamentos Cloud y transición On-Premise hacia AWS	Conceptual + guiada
2	M1	S3, IAM, Lakehouse y arquitectura moderna	Arquitectura + decisiones
3	M2	Tour integral de la plataforma Databricks	Demostración + exploración
4	M2	Notebooks, SQL Editor, Compute y trabajo multilenguaje	Práctica guiada
5	M3	Data Ingestion, Catalog y Visual Data Prep	Práctica guiada
6	Evaluación	Repaso aplicado y Evaluación 1	Reto de plataforma
7	M4	Delta Lake y Medallion: Bronze, Silver y Gold	Caso práctico
8	M5	SQL, Python y PySpark: cuándo usar cada alternativa	Práctica comparativa
9	M6	Lakeflow Pipelines, incremental, calidad y trazabilidad	Construcción de flujo
10	M7	Databricks SQL, indicadores y AI/BI Dashboards	Taller analítico
11	M7	Jobs, Tasks, programación, monitoreo y Alerts	Automatización práctica
12	Evaluación	Repaso aplicado y Evaluación 2	Reto integrado
13	M8	Unity Catalog, permisos, seguridad y lineage	Práctica + análisis
14	M8	Organización, reutilización, Git y eficiencia de recursos	Taller de buenas prácticas
15	M9	Modelos analíticos y MLflow desde la perspectiva del usuario	Demostración + práctica
16	M9	Genie Code, Genie Agents y asistentes sobre datos	Práctica de IA
17	M10	Databricks Apps, Data Products y preparación final	Demo + diseño aplicado
18	Evaluación	Elaboración del caso de uso final	Evaluación aplicada

7. Desarrollo de las sesiones y actividades

Sesión 1 — Fundamentos Cloud y transición On-Premise hacia AWS

El alcance y los materiales de esta sesión se conservan sin modificaciones.

Temas

- On-Premise y Cloud.
- IaaS, PaaS y SaaS.
- Elasticidad, escalabilidad y alta disponibilidad.
- Regions y Availability Zones.
- Modelo de responsabilidad compartida.
- Seguridad Cloud introductoria.

Actividad

Analizar la modernización de un proceso ficticio de pólizas y siniestros desde infraestructura On-Premise hacia AWS, identificando responsabilidades, ventajas y riesgos.

Sesión 2 — S3, IAM, Lakehouse y arquitectura moderna

Temas

- Amazon S3: buckets, objetos, prefijos y zonas de datos.
- IAM, roles, policies y mínimo privilegio.
- Cifrado, KMS, VPC y tagging a nivel conceptual.
- Data Warehouse, Data Lake y Lakehouse.

- Separación entre almacenamiento y procesamiento.
- Ubicación de Databricks dentro de una arquitectura moderna sobre AWS.

Actividad

Crear un bucket de entrenamiento con nombre globalmente único, cargar archivos sintéticos de pólizas, siniestros y pagos mediante `aws s3 cp` y `aws s3 sync`, y verificar sus object keys. Después, completar la arquitectura On-Premise → S3 → Databricks → consumo analítico y asignar permisos mínimos a los perfiles de ingesta, procesamiento, análisis y auditoría.

La práctica se realizará en AWS CloudShell o mediante un perfil AWS CLI con credenciales temporales. Si el participante no tiene permisos, utilizará un prefijo aislado de un bucket compartido o una salida simulada.

Resultado verificable

Bucket o evidencia simulada con tres objetos organizados, comparación entre Console, `cp`, `sync` e ingesta automatizada, diagrama de arquitectura y matriz de permisos mínimos.

Sesión 3 — Tour integral de la plataforma Databricks

Temas

- Data Intelligence Platform.
- Workspace y organización de activos.
- Catalog Explorer.
- Compute y SQL Warehouses.
- SQL Editor y notebooks.
- Data Ingestion y Visual Data Prep.
- AI/BI Dashboards.
- Jobs & Pipelines.
- Alerts.
- Experiments, Models y MLflow.
- Genie Code, Genie Agents y Databricks Apps.

Actividad

Realizar una exploración guiada del workspace y completar un mapa “necesidad → herramienta”. Cada participante deberá localizar los componentes y seleccionar cuál usaría para consultar datos, preparar información, publicar un indicador, automatizar una tarea o formular una pregunta de negocio.

Resultado verificable

Mapa funcional de la plataforma completado con cinco decisiones justificadas.

Sesión 4 — Notebooks, SQL Editor, Compute y trabajo multilenguaje

Temas

- Creación y organización de notebooks.
- Selección de compute según el trabajo.
- SQL Editor y consultas guardadas.
- Celdas SQL, Python y PySpark.
- Visualizaciones desde resultados.
- Documentación y colaboración.
- Genie Code para generar, explicar y corregir consultas o código.
- Cuándo utilizar notebook, SQL Editor o herramienta visual.

Actividad

Explorar una tabla pequeña de pólizas con SQL, reutilizar el resultado desde Python y revisar una transformación equivalente con PySpark. Utilizar Genie Code, si está habilitado, para explicar la lógica y proponer una mejora; luego validar manualmente la respuesta.

Resultado verificable

Notebook documentado con una consulta, una transformación sencilla, una visualización y la explicación de qué lenguaje conviene en cada paso.

Sesión 5 — Data Ingestion, Catalog y Visual Data Prep

Temas

- Carga de archivos CSV, JSON y Excel.
- Creación de tablas desde archivos.
- Navegación y descubrimiento en Catalog Explorer.
- Schema inference y revisión de tipos.
- Visual Data Prep con Lakeflow Designer.
- Operadores visuales de selección, filtro, limpieza y agregación.
- Relación entre transformación visual y código generado.
- Tabla frente a vista y reutilización de activos existentes.

Actividad principal

Cargar un archivo sintético de pagos, registrarlo como tabla, identificar su schema y construir una preparación visual para estandarizar estados, corregir tipos y calcular un resumen por medio de pago.

Opción alternativa

Si Visual Data Prep no está habilitado, realizar la misma preparación mediante SQL y comparar conceptualmente ambas experiencias.

Resultado verificable

Tabla preparada, reglas aplicadas y decisión justificada entre tabla, vista o salida temporal.

Sesión 6 — Repaso aplicado y Evaluación 1

No se introduce contenido nuevo.

Actividad

Resolver un reto guiado en el que el participante recibe una necesidad de reportería, identifica las herramientas correctas, localiza o carga un dataset, explora el Catalog, ejecuta una consulta y presenta una visualización sencilla.

Conocimientos evaluados

- fundamentos Cloud, S3 e IAM
- arquitectura Lakehouse
- navegación por Workspace y Catalog
- selección de Compute, SQL Editor o notebook
- ingesta y preparación básica
- elección de la herramienta adecuada

Sesión 7 — Delta Lake y arquitectura Medallion

Temas

- Delta Lake y Transaction Log.
- Beneficios ACID y versionamiento.
- Tablas Managed y External.
- Bronze, Silver y Gold.

- Trazabilidad, reprocesamiento y calidad por capa.
- `INSERT`, `UPDATE`, `DELETE`, `MERGE` y Time Travel a nivel aplicado.
- Preparación de Gold para Analytics y BI.

Actividad

Clasificar datasets y transformaciones de pólizas, productos y siniestros en la capa correspondiente; construir una ruta simplificada Bronze → Silver → Gold y comprobar un cambio de versión en Delta.

Resultado verificable

Tres activos diferenciados por capa y una explicación de qué transformación pertenece a cada una.

Sesión 8 — SQL, Python y PySpark aplicados

Temas

- SQL para consulta, agregación y análisis.
- Python para lógica complementaria y análisis.
- PySpark para transformación distribuida.
- DataFrames, Transformations, Actions y Lazy Evaluation a nivel fundamental.
- `select`, `filter`, `withColumn`, `groupBy` y joins.
- Combinación de lenguajes dentro de un mismo flujo.
- Criterios de elección: perfil, volumen, complejidad, mantenimiento y consumo.

Actividad

Resolver un indicador de siniestros primero con SQL y revisar su equivalente en PySpark. Utilizar Python para una validación o visualización complementaria y comparar claridad, reutilización y esfuerzo.

Resultado verificable

Una solución funcional y una matriz breve que indique cuándo conviene SQL, Python, PySpark o una preparación visual.

Sesión 9 — Lakeflow Pipelines, incremental, calidad y trazabilidad

Temas

- ETL y ELT dentro de Databricks.
- Batch, Streaming, Full e Incremental Load.
- Lakeflow Pipelines y editor de pipelines.
- Auto Loader y `COPY INTO` a nivel introductorio.
- Schema evolution, checkpoints e idempotencia.
- Expectations y reglas de calidad.
- Dependencias y flujo de origen a consumo.
- Registros válidos e inválidos.

Actividad principal

Construir o completar un pipeline de siniestros que reciba archivos diarios, aplique una regla de calidad y publique una tabla preparada para análisis.

Opción alternativa

Cuando Pipelines no esté disponible, ejecutar notebooks secuencialmente y representar las dependencias mediante un DAG.

Resultado verificable

Pipeline o DAG con fuente, transformación, regla de calidad y salida identificadas.

Sesión 10 — Databricks SQL, indicadores y AI/BI Dashboards

Temas

- SQL Warehouse y SQL Editor.
- Consultas guardadas y vistas.
- Datasets para dashboards.
- Indicadores, visualizaciones y filtros.
- Diseño de AI/BI Dashboards.
- Publicación, permisos y experiencia del consumidor.
- Métricas consistentes y reutilización de tablas Gold.
- Cuándo utilizar consulta, vista, dashboard o exportación.

Actividad

Construir un dashboard operativo de siniestros con indicadores de cantidad, monto pagado, estado y evolución temporal. Agregar filtros útiles para un supervisor y documentar la fuente Gold utilizada.

Resultado verificable

Dashboard con al menos tres indicadores, dos visualizaciones y un filtro de negocio.

Sesión 11 — Jobs, Tasks, programación, monitoreo y Alerts

Temas

- Lakeflow Jobs, Tasks y DAGs.
- Dependencias y parámetros.
- Scheduling y triggers.
- Ejecución de notebooks, pipelines y consultas SQL.
- Retries, repair y rerun.
- Run History y monitoreo.
- Manejo de errores y notificaciones.
- Databricks SQL Alerts para métricas de negocio y calidad.
- Automatización de procesos repetitivos de reportería.

Actividad principal

Configurar un Job que actualice una tabla Gold y después ejecute la consulta que alimenta un reporte. Revisar una falla controlada, identificar la tarea afectada y definir una alerta para una condición de negocio.

Opción alternativa

Si la creación de Jobs o Alerts está restringida, realizar la configuración como demostración y completar el DAG, la condición y el procedimiento de recuperación en una plantilla.

Resultado verificable

DAG con tareas, dependencia, horario, parámetro, estrategia de error y alerta.

Sesión 12 — Repaso aplicado y Evaluación 2

No se introduce contenido nuevo.

Actividad

Resolver un reto integrado desde una fuente de datos hasta su consumo: elegir la herramienta de preparación, ubicar cada resultado en Bronze, Silver o Gold, aplicar una transformación con SQL o PySpark, definir el pipeline, crear un indicador y proponer su automatización.

Conocimientos evaluados

- uso y selección de herramientas de Databricks

- arquitectura Medallion y Delta Lake
- SQL, Python y PySpark a nivel fundamental
- ingesta Full o Incremental
- pipeline, calidad e idempotencia
- dashboard, Job, monitoreo y Alert

Sesión 13 — Unity Catalog, permisos, seguridad y lineage

Temas

- Metastore, Catalog, Schema, Table, View y Volume.
- Descubrimiento y documentación de datos.
- Usuarios, grupos y Service Principals.
- Ownership y permisos.
- [GRANT](#), [REVOKE](#) y mínimo privilegio.
- Lineage y trazabilidad.
- Tags y clasificación.
- Row Filters, Column Masking y ABAC como overview.
- Storage Credentials y External Locations a nivel conceptual.

Actividad

Organizar activos de pólizas y siniestros dentro de Catalog y Schema, asignar permisos mínimos a un Data Engineer, un analista y un supervisor, y observar o interpretar el lineage desde la tabla Silver hasta el dashboard.

Resultado verificable

Matriz de permisos y recorrido de lineage con origen, transformación y consumidor.

Sesión 14 — Organización, reutilización, Git y eficiencia de recursos

Temas

- Cuándo utilizar tabla, vista, notebook, pipeline, consulta o dashboard.
- Reutilización y prevención de duplicidad.
- Naming, folders, dominios y ambientes.
- Separación entre configuración y lógica.
- Parámetros, metadata y logging.
- Git Folders, commits, branches y Pull Requests.
- CI/CD y promoción como overview.
- Bundles, YAML, CLI y Terraform como overview.
- Selección eficiente de compute, costos y FinOps.

Actividad

Revisar un workspace desorganizado, detectar duplicidades y proponer una estructura reutilizable. Refactorizar un notebook para separar configuración y lógica, registrar el cambio en Git o simular el flujo de revisión.

Resultado verificable

Propuesta de organización, activo corregido y checklist de buenas prácticas.

Sesión 15 — Modelos analíticos y MLflow

Temas

- De la pregunta de negocio al modelo analítico.
- Preparación de variables y separación de datos.

- Diferencia entre análisis descriptivo y predictivo.
- Experiments y Runs en MLflow.
- Parámetros, métricas y artefactos.
- Interpretación de resultados y limitaciones.
- AutoML y Model Serving como overview.
- Gobierno de modelos y uso responsable.

Actividad principal

Partir de una tabla Gold preparada para analizar pagos tardíos, ejecutar o revisar un modelo sencillo ya parametrizado y comparar dos Runs en MLflow. El objetivo será interpretar métricas y limitaciones, no programar un algoritmo avanzado.

Opción alternativa

Si el entrenamiento o MLflow está restringido, analizar capturas y resultados precalculados manteniendo la toma de decisiones.

Resultado verificable

Selección justificada de un Run y explicación de qué decisión permite apoyar.

Sesión 16 — Genie Code, Genie Agents y asistentes sobre datos

Temas

- IA generativa dentro de Databricks.
- Genie Code para SQL, Python, notebooks, pipelines y dashboards.
- Buenas prácticas de prompting y validación humana.
- Riesgos de respuestas incorrectas y control de permisos.
- Genie Agents para preguntas sobre datos de negocio.
- Contexto, instrucciones, términos, ejemplos y datos certificados.
- Consulta conversacional y revisión del SQL generado.
- AI Playground y agentes personalizados como overview.

Actividad principal

Utilizar Genie Code para generar o explicar una consulta y validarla contra los datos. Configurar o explorar un Genie Agent conectado a indicadores Gold de siniestros, formular preguntas de negocio y revisar la trazabilidad de las respuestas.

Opción alternativa

Si Genie Agents no está habilitado, utilizar una demostración grabada o guiada y diseñar las instrucciones, preguntas de ejemplo y controles del asistente.

Resultado verificable

Consulta validada y ficha de un asistente con propósito, fuentes, usuarios, preguntas admitidas y límites.

Sesión 17 — Databricks Apps, Data Products y preparación final

Temas

- Databricks Apps y casos de uso empresariales.
- Aplicaciones conectadas a Databricks SQL y Unity Catalog.
- Diferencia entre dashboard, Genie Agent y aplicación.
- Data Product: owner, consumidores, contrato y documentación.
- Freshness, calidad, seguridad, SLA y SLO.
- Views, sharing y disponibilización.
- Data Mesh y ownership por dominio a nivel introductorio.

- Preparación y criterios del caso de uso final.

Actividad principal

Explorar o desplegar una aplicación sencilla conectada a datos Gold y definir un Data Product de indicadores de siniestros. Comparar si la necesidad debe resolverse con un dashboard, Genie Agent o Databricks App.

Opción alternativa

Si Apps no está habilitado, revisar la aplicación como demo y construir su wireframe, recursos, permisos y flujo de datos.

Resultado verificable

Ficha de Data Product y decisión justificada del canal de consumo.

Sesión 18 — Caso de uso final

Los 120 minutos se destinan íntegramente a elaborar y entregar una solución integrada para una aseguradora ficticia. Los datasets, plantillas y activos base estarán disponibles antes de iniciar.

Actividad

El participante deberá resolver una necesidad de información operativa y:

- seleccionar las herramientas adecuadas de Databricks
- preparar o reutilizar los datos proporcionados
- aplicar una estructura Medallion simplificada
- crear una tabla o vista Gold verificable
- construir un indicador y su visualización
- proponer la automatización y el monitoreo del flujo
- establecer permisos y buenas prácticas mínimas
- explicar cómo podría consumirse mediante dashboard, Genie Agent o App
- entregar evidencias y decisiones justificadas

No se exige implementar todas las funcionalidades de la plataforma. La evaluación prioriza la selección correcta de herramientas, la integración del flujo y la capacidad de conectar el resultado con una necesidad del negocio.

8. Estrategia de evaluación

Evaluación	Fecha	Alcance	Peso
Repaso aplicado y Evaluación 1	05 de octubre de 2026	Sesiones 1 a 5	30%
Repaso aplicado y Evaluación 2	28 de octubre de 2026	Sesiones 1 a 11	30%
Caso de uso final	25 de noviembre de 2026	Integración del programa	40%

Las evaluaciones medirán la capacidad de aplicar y seleccionar herramientas, no la memorización de comandos ni la programación avanzada con Spark.

Evaluación 1

Comprueba fundamentos Cloud y Lakehouse, navegación en Databricks, uso de Workspace, Catalog, Compute, SQL Editor, notebooks, ingesta y preparación básica. No requiere Spark avanzado.

Evaluación 2

Añade Delta Lake, Medallion, elección entre SQL/Python/PySpark, pipelines, calidad, dashboards, Jobs, monitoreo y Alerts. No evalúa funcionalidades de IA, Apps o gobierno presentadas después de la Sesión 12.

Caso de uso final

Integra plataforma, datos y negocio. El participante debe entregar una solución acotada y funcional, acompañada por decisiones justificadas de automatización, gobierno y consumo.

9. Matriz de cobertura solicitada por el cliente

Necesidad	Sesiones principales	Actividad
Workspace, Catalog y Compute	3, 4, 5, 13	Exploración, carga, consulta y organización
SQL Editor, SQL, Python y PySpark	4, 8	Flujo multilenguaje y comparación práctica
Data Ingestion y Visual Data Prep	5, 9	Carga, preparación visual y pipeline
Delta Lake y Medallion	7, 9	Bronze → Silver → Gold
Dashboards y Analytics	10	Dashboard operativo de siniestros
Jobs, Tasks y Pipelines	9, 11	Pipeline y automatización de reportería
Monitoreo, errores y Alerts	11	Falla controlada, recuperación y alerta
Gobierno, seguridad y lineage	13	Permisos por perfil y trazabilidad
Organización, Git y costos	14	Revisión y refactorización del workspace
Modelos analíticos y MLflow	15	Comparación e interpretación de Runs
IA generativa y Genie Code	4, 16	Generación, explicación y validación
Genie Agents y asistentes	16	Consulta conversacional sobre tablas Gold
Databricks Apps	17	Demo o aplicación conectada a datos
Data Products y consumo	17, 18	Selección de dashboard, agente o App

10. Caso asegurador transversal

Los ejercicios emplearán una aseguradora ficticia y datos 100% sintéticos. No se asumirán sistemas, arquitectura, datos ni reglas internas de La Positiva.

```

asegurados
  ■■■ polizas ■■ productos
    ■■■ pagos
    ■■■ siniestros ■■ proveedores
  
```

El caso evolucionará progresivamente:

```

Fuente
↓
Ingesta y Catalog
↓
Bronze → Silver → Gold
↓
SQL y Analytics
↓
Dashboard y Alert
↓
Job y monitoreo
↓
Gobierno
↓
Genie Agent / App / Data Product
  
```

11. Compatibilidad y alternativas

Las capacidades disponibles pueden variar entre Databricks Free Edition y el entorno corporativo. Cada práctica dependiente de una función específica tendrá:

```

Opción A – práctica principal en la funcionalidad prevista
Opción B – alternativa compatible o simulación guiada
Qué cambia en un entorno empresarial
  
```

Las prácticas se clasificarán como:

- **PRACTICO_FREE**: ejecutable directamente en Free Edition.
- **PRACTICO_CONDICIONAL**: depende de permisos, cuotas o funciones habilitadas.

- **DEMO_INSTRUCTOR**: demostrado por el instructor.
- **CONCEPTUAL**: análisis, diseño o selección de herramienta.

Ninguna evaluación dependerá obligatoriamente del acceso directo a S3, de permisos administrativos ni de una función no habilitada para el participante.

12. Buenas prácticas transversales

Durante todas las actividades se reforzará:

- revisar si el activo ya existe antes de crear uno nuevo
- utilizar tablas Gold y vistas compartidas para evitar duplicidad
- elegir la herramienta más simple que resuelva la necesidad
- documentar propósito, owner, fuente y consumidores
- utilizar nombres claros y organización por dominio
- separar configuración, lógica y presentación
- aplicar mínimo privilegio
- validar resultados generados por IA
- considerar consumo, mantenimiento y costo
- proteger credenciales y datos sensibles

13. Requisitos de los participantes

- Conocimientos básicos de datos y reportería.
- Conocimientos básicos de SQL deseables.
- No se requiere experiencia avanzada en programación o Spark.
- Laptop con navegador y acceso a Internet.
- Cuenta Databricks Free Edition o acceso al entorno habilitado.
- Cuenta GitHub para las actividades de versionamiento.

14. Entregables del programa

- Presentaciones y guías por sesión.
- Mapa funcional de la plataforma Databricks.
- Ejercicios de navegación, ingesta y preparación visual.
- Notebooks y consultas SQL de ejemplo.
- Pipeline Medallion con reglas de calidad.
- Dashboard e indicador operativo.
- Job, DAG, estrategia de monitoreo y Alert.
- Matriz de permisos y evidencia de lineage.
- Ejercicio de MLflow e interpretación analítica.
- Ficha de Genie Agent o asistente.
- Demo o diseño de Databricks App.
- Ficha de Data Product.
- Dos repasos aplicados y un caso de uso final.