

Especialización en Databricks Associate

Sesión 2

Docente: Juan Salinas

Capacitación Corporativa



Acuerdos para la sesión:

- **Puntualidad**

Se requiere puntualidad para un mejor desarrollo del curso.

- **Celulares o Micrófonos en silencio**

Es necesario que los celulares o Micrófonos permanezcan en silencio durante la clase para no interrumpir la sesión.

- **Preguntas y consultas**

Las preguntas pueden realizarse en cualquier momento. Las consultas muy particulares se revisarán al final de la clase.

- **Cumplimiento de tareas**

Realizar las actividades y/o tareas encomendadas dentro de los plazos establecidos.



Criterios de Evaluación



Horario:
8:00 PM a 10:00 PM

SEPTIEMBRE 2026						
Lu	Ma	Mi	Ju	Vi	Sa	Do
31	1	2	3	4	5	6
7	8	9	10	11	12	13
14	15	16 INICIO	17	18	19	20
21	22	23	24	25	26	27
28	29	30	1	2	3	4

OCTUBRE 2026						
Lu	Ma	Mi	Ju	Vi	Sa	Do
28	29	30	1	2	3	4
5	6	7	8	9	10	11
12	13	14	15	16	17	18
19	20	21	22	23	24	25
26	27	28	29	30	31	1

NOVIEMBRE 2026						
Lu	Ma	Mi	Ju	Vi	Sa	Do
26	27	28	29	30	31	1
2	3	4	5	6	7	8
9	10	11	12	13	14	15
16	17	18	19	20	21	22
23	24	25	26	27	28	29
30	1	2	3	4	5	6

Leyenda

- **Inicio del curso**
16 de septiembre
- **Evaluación**
5 de octubre, 28 de octubre, 25 de noviembre
- **Sesiones programadas**
Días de clases regulares
- **Feriado**
No hay clases

Fechas de evaluaciones

- Sesión 6:** 5 de octubre
- Sesión 12:** 28 de octubre
- Sesión 18:** 25 de noviembre

Requisitos académicos



Asistencia a clases:
mínimo 80%



- Ponderación:**
- 30% Laboratorio 1
 - 30% Laboratorio 2
 - 40% Caso final



Agenda:

- **Cloud Computing**
Concepto y beneficios principales
- **On-Premises vs Cloud**
Diferencias en operación y gestión
- **IaaS, PaaS, SaaS y Serverless**
Modelos de servicio en la nube
- **Modelo de responsabilidad compartida**
Qué gestiona el proveedor y qué gestiona el cliente
- **Principios básicos de seguridad Cloud**
Acceso, protección y buenas prácticas
- **Laboratorio 01: Accediendo al entorno de AWS y Databricks Free Edition**
Primer acceso al entorno de trabajo

¿Qué es Amazon S3?

Servicio de almacenamiento de objetos en la nube de AWS



Amazon S3 permite **almacenar y recuperar** archivos desde cualquier lugar.



La información se guarda como **objetos** dentro de buckets.



Es **escalable, durable, seguro** y de **alta disponibilidad**.



Conceptos clave



Bucket:
contenedor lógico de almacenamiento



Objeto:
archivo + metadatos



Escalabilidad:
crece según la necesidad



Seguridad:
cifrado, control de acceso y versionado



Buckets en Amazon S3

Contenedores de datos en la nube



¿Qué es un bucket?

Un bucket es el contenedor básico de Amazon S3 donde se almacenan los objetos. Cada bucket tiene un nombre único a nivel global y una región definida.



Propiedades clave



Nombre único

A nivel global



Región

Define dónde se almacenan los datos



Configuración

Seguridad, versionado, cifrado, etc.



Políticas de acceso

Control de permisos (IAM, bucket policy)



Almacenar datos

Archivos de cualquier tipo y tamaño (logs, backups, imágenes, datos de analítica, etc.)



Intercambio de datos

Compartir datos de forma segura entre aplicaciones, equipos o cuentas de AWS.



Data Lake

Base para implementar arquitecturas analíticas y de machine learning.



Alta durabilidad y disponibilidad


Diseñado para 99.999999999% (11 nueves) de durabilidad.





Objetos, prefijos y zonas de datos en Amazon S3

Organiza y gestiona tus datos usando una estructura jerárquica de prefijos



1



Objetos

Un objeto es el archivo que almacena tus datos y su metadata (clave, valor, tamaño, fecha, etc.). Puede ser cualquier tipo de archivo: CSV, Parquet, JSON, imágenes, logs, etc.

2



Prefijos

Los prefijos permiten organizar los objetos dentro de un bucket usando una estructura jerárquica similar a carpetas.

S3 no tiene carpetas reales, los prefijos son parte del nombre del objeto (por ejemplo: brz/ventas_2024.csv).

3



Zonas de datos

Una buena práctica es organizar los datos en zonas como Bronze, Silver y Gold, usando prefijos. Esto facilita la gobernanza, el control de accesos y la implementación de arquitecturas de datos (Data Lake) sobre S3.



Bronze (brz/)

Datos en crudo (sin procesar)




Silver (slv/)

Datos limpios y conformados



Gold (gld/)

Datos listos para consumo



Cifrado en Amazon S3

Protege tus datos en reposo y en tránsito



¿Qué es el cifrado?

El cifrado transforma tus datos en un formato ilegible (texto cifrado) para protegerlos contra accesos no autorizados. Solo los usuarios o servicios con las claves correctas pueden descifrarlos y leerlos.



¿Por qué es importante?

El cifrado en Amazon S3 ayuda a proteger la confidencialidad, integridad y cumplimiento de los datos, y es una práctica recomendada para cumplir con requisitos regulatorios y de seguridad.



Tipos de cifrado

SSE-S3

Cifrado administrado por Amazon S3



Amazon S3 administra automáticamente las claves de cifrado. Sin costo adicional.

SSE-KMS

Cifrado con AWS KMS



Utiliza claves administradas por AWS Key Management Service (KMS). Permite mayor control, auditoría y políticas de uso.

SSE-C

Cifrado con claves provistas por el cliente



El cliente proporciona y administra sus propias claves de cifrado.



Beneficios



Protección de datos sensibles



Cumplimiento normativo



Mayor control y auditoría



Práctica recomendada de seguridad



AMAZON IAM



¿QUÉ ES AMAZON IAM?

Amazon IAM es un servicio web que permite gestionar de forma segura el acceso a los recursos de AWS. Te permite controlar quién está autenticado (firmado) y autorizado (tiene permisos) para usar recursos.





AWS Identity and Access Management

Apply fine-grained permissions to AWS services and resources



Who

Workforce users and workloads with IAM



Can access

Permissions with IAM policies



What

Resources within your AWS organization



AWS IAM: Usuarios, Grupos, Roles y Políticas

Conceptos básicos para gestionar acceso y permisos en AWS



Tipos de acceso

- **Usuario IAM:** identidad creada dentro de AWS con credenciales y permisos definidos.
- **Usuario federado:** accede desde un proveedor externo de identidad y usa credenciales temporales.
- **Usuario raíz:** cuenta inicial con acceso total. No se recomienda para tareas diarias.



Usuarios y grupos



Los grupos facilitan asignar permisos a varios usuarios.



Roles

- Un rol es una identidad que se puede asumir temporalmente para obtener permisos.
- Se usa para delegar acceso entre usuarios, servicios o cuentas.



Políticas

- Una política es un documento JSON que define permisos.
- Especifica qué acciones se permiten o deniegan sobre qué recursos.

```

json
1 {
2   "Versión": "2012-10-17",
3   "Declaración": [
4     { "Efecto": "Permitir",
5       "Acción": "s3:ListBucket",
6       "Recurso": "arn:aws:s3:::mi-bucket"
7     }
  ]
}
  
```



¿Cómo se relacionan?




Buenas prácticas: usar grupos para usuarios, roles para acceso temporal y políticas de mínimo privilegio.

MEJORES PRÁCTICAS Y SEGURIDAD



Principio de privilegio mínimo

- El principio de privilegio mínimo sugiere que a un usuario, grupo, rol o aplicación se le deben **otorgar solo los permisos necesarios para realizar sus tareas específicas, y nada más**. Esto reduce la superficie de ataque y limita el daño potencial en caso de una violación de seguridad.
- Al crear políticas de IAM, asegúrate de otorgar solo los permisos necesarios. Por ejemplo, si un usuario necesita acceder solo a un bucket específico de S3, no le des acceso a todos los buckets de S3.



Rotación de credenciales

- La rotación de credenciales implica **cambiar regularmente las claves de acceso y las contraseñas para reducir el riesgo de compromiso**. AWS recomienda rotar las claves de acceso al menos cada 90 días.
- Puedes configurar políticas de contraseña en IAM para exigir la rotación de contraseñas. Para las claves de acceso, puedes crear nuevas claves y desactivar o eliminar las antiguas regularmente.

Edit rotation configuration

Configure automatic rotation

Configure AWS Secrets Manager to rotate this secret automatically.

☒ Automatic rotation

Rotation schedule

☒ Schedule expression builder

☐ Schedule expression

Time unit

Days

Days ▼

60

Window duration - optional

4h

Enter the time in hours.

☐ Rotate immediately when the secret is stored. The next rotation will begin on your schedule.





AWS KMS

Key Management Service

Crea, administra y utiliza claves de cifrado de forma segura y escalable



¿Qué es AWS KMS?

AWS Key Management Service (KMS) es un servicio administrado que te permite crear, administrar y utilizar claves de cifrado para proteger tus datos en AWS y en aplicaciones.

KMS se integra con servicios de AWS como Amazon S3, EBS, RDS, Lambda, entre otros, para habilitar el cifrado de datos de forma simple y segura.



Conceptos clave

Claves (Keys)

Puedes crear claves administradas por AWS o claves administradas por el cliente (CMK).



Políticas de clave

Controlan quién puede usar la clave y qué operaciones puede realizar.



Integración nativa

KMS se integra con múltiples servicios de AWS sin necesidad de administrar infraestructura adicional.



Auditoría

Todas las operaciones se registran en AWS CloudTrail.



Beneficios



Mayor seguridad

Protege tus claves y datos con controles de acceso avanzados.



Escalabilidad

Servicio totalmente administrado.



Cumplimiento

Ayuda a cumplir con requisitos regulatorios.



Integración simple

Funciona de forma nativa con servicios de AWS.



Casos de uso comunes

- ✓ Cifrado de objetos en Amazon S3 (SSE-KMS)
- ✓ Cifrado de volúmenes en Amazon EBS
- ✓ Cifrado de bases de datos en Amazon RDS
- ✓ Cifrado de variables y secretos en AWS Secrets Manager
- ✓ Protección de datos en aplicaciones y microservicios



Documentación oficial

<https://docs.aws.amazon.com/kms/latest/developerguide/what-is-kms.html>

AWS Key Management Service
Developer Guide

Amazon VPC

Tu red privada en la nube



¿Qué es?

Una VPC (Virtual Private Cloud) es una **red virtual y aislada** en la nube donde puedes lanzar tus recursos de forma segura y con control total sobre su conectividad.



¿Por qué es importante?

- ✓ Aisla tus recursos.
- ✓ Te da control sobre la conectividad.
- ✓ Permite una arquitectura segura y escalable.
- ✓ Es la base para construir aplicaciones en la nube.



Componentes principales



Subredes

Segmentos de la VPC donde se lanzan los recursos.



Tablas de enrutamiento

Definen a dónde se envía el tráfico de la subred.



Security Groups

Firewall a nivel de instancia que controla el tráfico entrante y saliente.




Network ACLs

Firewall a nivel de subred que controla el tráfico entrante y saliente.



Ejemplo de arquitectura



AWS Tagging

Organiza · Controla · Gestiona · Escala

¿Qué es?



Es una forma de asignar metadatos (etiquetas) a tus recursos de AWS para identificarlos y clasificarlos de manera sencilla.

Estructura

Clave

:

Valor

Cada tag tiene una clave y un valor.

¿Por qué es importante?

- ✓ Mejora la visibilidad de tus recursos
- ✓ Facilita la gestión y el escalamiento
- ✓ Permite un mejor control de costos
- ✓ Apoya el cumplimiento y la seguridad

Ejemplos de tags

Environment	:	Production
Project	:	Website
Owner	:	team-dev
CostCenter	:	CC1234

Casos de uso



Organización

Clasifica y agrupa recursos fácilmente.



Control de costos

Asigna y analiza gastos por tags.



Gobierno

Aplica políticas y cumplimiento.



Seguridad

Controla el acceso y la visibilidad.



Automatización

Usa tags en scripts y políticas.



Data Warehouse

Un **Data Warehouse** es un repositorio centralizado de datos integrados, históricos y estructurados, diseñado para el análisis y la toma de decisiones.

Características principales



¿Cómo funciona?



Data Lake

Repositorio central que almacena grandes volúmenes de datos en su formato original, sin necesidad de estructurarlos previamente.

Fuentes diversas

-  Bases de datos
-  Archivos
-  Multimedia
-  Sensores y dispositivos
-  Aplicaciones y APIs
-  Redes sociales



Procesamiento y analítica

-  Transformación de datos
-  Analítica y visualización
-  Inteligencia artificial y machine learning
-  Ingeniería de datos y nuevos casos de uso

Características principales


Almacena datos estructurados, semiestructurados y no estructurados


Almacenamiento escalable


Datos en bruto en su formato original


Flexibilidad para analítica e ingeniería de datos


Soporta grandes volúmenes de datos

Lakehouse

Una única plataforma para todos tus datos y analítica



Características principales



Separación entre almacenamiento y procesamiento

El almacenamiento guarda los datos y el procesamiento ejecuta el cómputo.
Pueden escalarse por separado, lo que brinda flexibilidad y eficiencia de costos.



Escalabilidad independiente

Ajusta almacenamiento y procesamiento según la necesidad.



Optimización de costos

Pagas solo por lo que usas en cada capa.




Flexibilidad

Permite adaptar la arquitectura a diferentes cargas de trabajo.



Ubicación de Databricks

dentro de una arquitectura moderna sobre AWS





Objetivo

Crear un bucket de entrenamiento, cargar archivos sintéticos de pólizas, siniestros y pagos usando AWS CLI, verificar sus object keys, completar la arquitectura On-Premise → S3 → Databricks → consumo analítico y asignar permisos mínimos por perfil.



Herramientas



AWS CloudShell
o AWS CLI
(con credenciales temporales)



Amazon S3



Databricks



Resultado verificable

- ✓ Bucket o evidencia simulada con tres objetos organizados.
- ✓ Comparación entre Console, cp, sync e ingesta automatizada.
- ✓ Diagrama de arquitectura.
- ✓ Matriz de permisos mínimos.



Pasos de la actividad

- 1 Crear un bucket de entrenamiento con nombre globalmente único.
- 2 Generar y preparar archivos sintéticos de pólizas, siniestros y pagos.
- 3 Cargar archivos usando **aws s3 cp** y **aws s3 sync**.
- 4 Verificar los object keys en el bucket.
- 5 Completar la arquitectura On-Premise → S3 → Databricks → consumo analítico.
- 6 Asignar permisos mínimos a los perfiles de ingesta, procesamiento, análisis y auditoría.
- 7 Documentar resultados y evidencias.



Arquitectura objetivo



Estructura de datos en S3



Comandos AWS CLI (ejemplos)

```
# 1. Crear bucket
aws s3 mb s3://mi-bucket-entrenamiento-unik123

# 2. Cargar archivos con cp
aws s3 cp ./data/polizas_2023.csv s3://mi-bucket-entrenamiento-unik123/polizas/

# 3. Cargar archivos con sync
aws s3 sync ./data/siniestros/ s3://mi-bucket-entrenamiento-unik123/siniestros/

# 4. Listar object keys
aws s3 ls s3://mi-bucket-entrenamiento-unik123/
--recursive
```



Perfiles y permisos mínimos

Perfil	Permisos mínimos	Propósito
Ingesta	s3:PutObject s3:ListBucket	Carga de archivos a S3.
Procesamiento	s3:GetObject s3:ListBucket	Lectura de datos para procesamiento en Databricks.
Análisis	s3:GetObject s3:ListBucket	Lectura para consultas y análisis.
Auditoría	s3:ListBucket s3:GetObject	Revisión y trazabilidad.



Entregables

- ✓ Evidencia del bucket y archivos cargados (o salida simulada).
- ✓ Capturas de Console, cp y sync.
- ✓ Lista de object keys.
- ✓ Diagrama de arquitectura.
- ✓ Matriz de permisos mínimos.

¡GRACIAS!

